

Антифрод-пайплайн: отчёт

Команда из трёх участниц: А — профиль клиента, В — ритм операций, С — экономика решения. Все числа ниже взяты из запусков (reports/experiments.csv, tournament.csv, economics.md). Периоды: обучение (train) — 01.01.2019–20.02.2020, проверка идей (valid) — 21.02–21.04.2020, отложенная проверка (holdout) — 22.04–21.06.2020.

1. Как мы поняли задачу

Банку нужна система, которая каждый день выбирает операции для проверки аналитиками. На данных с этим столкнулись сразу:

- мошенничества 0,58% операций — примерно **14 в день**;
- аналитики успевают **0,3% — около 7 в день**.

Даже идеальная модель не отправит на проверку весь фрод. Поэтому вопрос не «какова вероятность мошенничества», а **«проверка каких 7 операций сегодня спасёт больше всего денег»**. Мы считаем экономию: сколько у.е. система сберегает по сравнению с «системы нет», с учётом цены проверки (3), ложной остановки честного клиента (25) и пропущенного фрода (сумма + 5).

Для ориентира мы посчитали **потолок** — экономию идеальной модели, которая знает правду и берёт самые дорогие фроды дня. На valid потолок 255 485 у.е. из 414 356 возможных потерь (62%). Большого при таком штате аналитиков не спасти.

2. Как проверяли

- Разбиение только по времени. Холдаут открыт один раз, для финального решения.
- Каждый признак проходит **тест на заглядывание в будущее**: признаки, посчитанные на данных до даты Т, должны совпасть с признаками, посчитанными на всём файле. Сам тест проверен на заведомо «подглядывающих» признаках — он их ловит.
- Признаки добавлялись **по одному**, для каждого записан вклад в у.е. и 90% интервал (бутстрэп по дням). Интервал, задевающий ноль, считаем шумом.
- Базовая модель (линейка): LightGBM на сырых полях — сумма, категория, час, день недели, возраст, пол, размер города.

3. Главный поворот: выбирать операции по деньгам

На блоке А признак «сумма выше обычной для клиента» улучшил распознавание (PR-AUC 0,48 → 0,71), но экономия упала на 43 тыс. у.е. Причина: операции отправлялись аналитикам по вероятности, и модель выбирала мелкий «очевидный» фрод вместо дорогого. После этого мы ранжируем по **ожидаемым потерям**: $p \cdot (\text{сумма} + 5) - 3 - (1 - p) \cdot 25$, и только если это число больше нуля.

Одна и та же базовая модель	valid	холдаут
отправлять самые вероятные	166 067 у.е.	220 219 у.е.
отправлять самые «дорогие» по ожиданию	235 437 у.е.	304 083 у.е.

Это самый большой эффект в проекте: +42% на valid без единого нового признака.

4. Три решения

А — «Сколько бит неожиданности». Сценарий: картой пользуется чужой человек с другими привычками. Каждая операция сравнивается с прошлым именно этой карты: насколько редка для неё категория, время суток, сумма в этой категории. Неожиданность считается в битах, профиль новой карты сглажен к «среднему клиенту», поэтому пропусков нет. Модель — логистическая регрессия: проверяли, хватит ли линейной модели. Сильнейшие признаки: сдвиг трат за последние дни (+17,2 тыс. у.е.) и «крупная сумма в непривычное время» (+18,7 тыс.). Итог на valid — 224 148 у.е. Гипотеза «хватит линейной модели» **не подтвердилась**: те же признаки на LightGBM дают 245 302.

В — «Атака как всплеск». Сценарий: карту «выкачивают» серией операций. В данных это подтверждается: у одной карты в среднем около 10 фрод-операций, и все укладываются в двое суток, медианная пауза между ними — час. Вместо окон «за 24 часа» используется затухающая память, где каждая прошлая операция плавно теряет вес. Активность сравнивается с обычным темпом этой карты, а поток режется на «сессии атаки». Модель — LightGBM, которому запрещено снижать риск при росте активности. Сильнейший признак: сколько денег списано за последние сутки (+10,9 тыс. у.е.). Итог на valid — 251 417 у.е. (98,4% потолка).

С — «Решение в деньгах». Сценарий: есть рискованная среда (категории, время, суммы), а решение принимается по деньгам. Риск среды считается с **задержкой меток 30 дней**, как в банке, где о мошенничестве узнают из жалобы клиента. Модель «учится деньгам»: дорогой фрод весит больше. Признаки среды дереву ничего не дали (LightGBM и так видит категорию и час), линейной модели дали +9,2 тыс. Главный вклад С — способ выбора операций (раздел 3), калибровка вероятностей и расчёт экономики. Итог на valid — 239 249 у.е.

5. Турнир и выбор финала

Все решения сравнивались одной политикой. Затем мы поменяли модели местами: каждый набор признаков прогнан на LogReg и трёх вариантах LightGBM (reports/tournament.md). Выводы:

- признаки А+В добавляют к сырым полям 13,6–14,8 тыс. у.е. в любом варианте LightGBM;
- варианты LightGBM между собой различаются не больше чем на 3,3 тыс. (шум);
- LogReg отстаёт на любых признаках, от 17 до 62 тыс.

Лучшие варианты различаются на сотни у.е., поэтому финал выбран по **разбору сценариев**. А лучше ловит первую операцию серии, когда вор ещё не «разогнался», В — продолжение серии. Объединение ловит оба сценария и реже всех останавливает честных клиентов: 27 за два месяца против 76 у базовой модели и 35 у В.

Финал: сырые поля + профиль А + ритм В + перцентиль суммы из С; LightGBM «учит деньгам»; выбор по ожидаемым потерям в пределах лимита. На valid — 252 522 у.е. (98,8% потолка).

6. Экономика на холдауте (два месяца, которые не использовались при выборе)

Потери без системы — 513 229 у.е. (948 мошеннических операций).

Вариант	Экономия, у.е.	Поймано фрода	Честных клиентов остановлено
Правило «проверять самые дорогие»	76 358	80	347
Базовая модель, по вероятности	220 219	379	48
Базовая модель, по деньгам	304 083	355	72
Финал	323 389	376	30
Потолок (идеальная модель)	327 812	389	0

Финал экономит 98,7% возможного (на valid было 98,8% — переобучения под проверочный период нет). Относительно правила по сумме — +247 032 у.е., относительно базовой модели с тем же способом выбора — +19 306 у.е.

Если мошенничества станет втрое больше: при том же лимите 0,3% доля спасённых денег остаётся около 63%, но пропущенный фрод вырастет до 558 875 у.е. за два месяца. При лимите 0,5% (≈10 проверок в день) пропуск падает до 232 918, при 1% (≈15 в день) — до 25 712. Дальше 1–1,5% (15–16 проверок в день) экономия почти не растёт. Это ответ на вопрос «сколько аналитиков нужно».

Цена ложной остановки (10 / 25 / 50 у.е.) почти не меняет экономию финала (323 670 / 323 389 / 322 957): решение устойчиво к этой оценке заказчика.

7. Что увидит аналитик

Каждой отправленной операции score.ru пишет три причины обычными словами. На холдауте у всех 406 отправленных операций есть три причины. Пример реальной пойманной операции:

08.06.2020 23:49, покупки в магазине, 1 215,89 у.е. 1. За последние сутки по карте уже списано около 4 870 у.е. 2. Сумма дороже 99% покупок в категории «покупки в магазине» 3. Серия из 5 операций ночью

Бывают и ложные тревоги: честная ночная покупка на 3 918,79 у.е. при вероятности 0,019 отправлена на проверку. Это осознанно: проверка стоит 3 у.е., а пропуск такой суммы — почти 3 924.

8. Отвергнутые идеи (подробно — [reports/feature_map.md](#))

- **Расстояние до продавца** — самый популярный признак на Kaggle. Распределения у фрода и честных совпадают (медиана 78,2 км и 78,2 км): в этом генераторе продавец ставится случайно рядом с домом.
- **Проверка карты мелкой суммой** — не подтвердилась ни со стороны профиля, ни со стороны серии: первая фрод-операция серии в медиане стоит 311 у.е. При этом рост суммы внутри серии работает (+2,4 тыс.).
- **Первая покупка у продавца** — у честных клиентов это 37% операций, денег не добавляет.
- **Разнообразие категорий в серии** — вредит (интервал ниже нуля).

- **Классическое окно «операций за 24 часа»** — поверх затухающей памяти ничего не даёт.
- **Риск категории/продавца (target encoding)** — дереву не нужен; полезен только линейной модели.
- **Обучение без меток (Isolation Forest)** — 167 тыс. против 235 тыс.: необычное ≠ мошенническое.
- **Линейной модели хватит** — нет, отставание от 17 тыс.

Как мы поняли, что дело в гипотезе, а не в проверке: у отвергнутых признаков либо распределения у фрода и честных совпадают (geo), либо интервал вклада ниже нуля. Судья, линейка и тест на утечку при этом одни и те же для всех признаков.

9. Работоспособность

`python train.py` обучает и сохраняет артефакты, `python score.py --input ... --output ...` — скоринг. На 550 000 строк — 32 секунды и 2 ГБ памяти (лимит 10 минут и 8 ГБ). Не падает на новой карте, новом продавце, новой категории, файле из одной строки, двух операциях в одну секунду, битой дате (`tests/test_score_robustness.py`, 11 из 11).

10. Как заметить, что модель портится

- Доля подтверждённого фрода среди проверенных (сейчас 376 из 406 ≈ 93%). Падение — первый сигнал.
- Сколько проверок в день реально уходит (сейчас ≈ 6,7 при лимите 7) и сколько дней лимит выбран полностью.
- Дрейф ключевых признаков: списано за сутки, перцентиль суммы в категории, неожиданность времени. Сравнение распределений месяц к месяцу.
- Экономия против правила «самые дорогие» на свежих подтверждённых данных.

Мошенники подстроятся — например, начнут тратить «как хозяин» и медленнее. Признаки ритма (B) обойти дороже всего: чтобы не выделяться, вору придётся тратить медленно. Модель нужно регулярно переобучать на свежих данных.

11. Что не успели и что сделали бы дальше

- Переобучить финал на всех данных до июня 2020 перед эксплуатацией (сдаём ту модель, которая прошла честную проверку).
- Настоящий потоковый режим: хранить состояние карты (счётчики, память), а не всю историю; суточный счётчик отправленных.
- Проверить, как меняется результат, если аналитики отвечают с задержкой.
- Эти данные синтетические (генератор Sparkov): часть выводов (geo бесполезно, мелкой проверки нет) может не перенестись на реальный банк.