

Шпаргалка к защите

Ответы простыми словами на все вопросы из раздела 11 ТЗ, плюс вопросы, которые, скорее всего, зададут следом. Каждая из нас должна уметь ответить на любой из них, а не только про своё решение. Все числа взяты из запусков (папка reports/).

Сначала — пять фраз, которые надо помнить наизусть

1. **Мошенничества ~14 операций в день, а проверить можно ~7** (лимит 0,3%). Даже идеальная модель спасла бы только 62% денег. Это наш «потолок».
2. **Выбираем не самые вероятные, а самые выгодные для проверки операции:** $\text{вероятность} \times (\text{сумма} + 5) - 3 - (1 - \text{вероятность}) \times 25$. На одной и той же модели это дало +69 тыс. у.е. (+42%).
3. **А — привычки клиента** (так хозяин не платит), **В — ритм операций** (карту выкачивают серией), **С — деньги** (что выгоднее проверить). В финале А + В + одна идея С, выбор по деньгам.
4. **Холдаут (22.04–21.06.2020) открыли один раз:** 323 389 у.е. экономии = 98,7% от возможного; 30 честных клиентов остановлено зря; 93% отправленного аналитикам — действительно мошенничество.
5. **Работу делают признаки и правило выбора, а не модель:** деревья разных видов отличаются в пределах шума (до 3,3 тыс.), а признаки А+В дают +14 тыс. на любом из них.

Словарик (как объяснять без терминов)

Слово	Как сказать просто
valid / проверочный период	21.02–21.04.2020: на нём сравнивали идеи
холдаут / отложенный период	22.04–21.06.2020: не трогали до самого конца, открыли один раз
потолок	сколько спасла бы модель, которая заранее знает правду, при том же числе аналитиков
интервал 90%	«с большой вероятностью эффект где-то тут». Если интервал задевает ноль — это может быть случайность
утечка / заглядывание в будущее	признак случайно использует то, чего в момент операции ещё не было
калибровка	подгонка, чтобы «вероятность 30%» и правда означала «3 из 10»
биты неожиданности (А)	1 бит — «так бывает в половине случаев», 7 бит — «1 раз из 128»
затухающая память (В)	каждая прошлая операция весит тем меньше, чем она старше, — без резкой границы «24 часа»
задержка меток (С)	банк узнаёт о мошенничестве не сразу, а после

Слово	Как сказать просто
	жалобы клиента; мы используем только метки старше 30 дней

Вопросы из ТЗ

1. Возьмите любой ваш признак: какую операцию он поймает, а сырые поля — нет?

«Сколько денег списано с карты за последние сутки» (В). Операция: покупка на 300 у.е. в продуктовом в 23:00. По сырым полям она обычная: сумма средняя, категория частая. Но если за последние сутки с этой карты уже ушло 4 870 у.е. при обычных ~190, это пятая операция в серии кражи. Сырая строка про прошлые операции ничего не знает. У мошенничества медиана этого признака 1 323 у.е., у честных — 188.

Запасные примеры: - **«Неожиданность времени» (А):** клиент два года платит только днём и вдруг платит в полночь. Сырой «час» говорит только «ночь рискованна вообще», а не «ночь необычна для этого человека». - **«Сдвиг трат» (А):** последние дни карта тратит в 1,6 раза крупнее обычного (у честных сдвига нет). Одна строка не видит, что поведение меняется серией.

2. Какая идея не сработала? Как вы поняли, что дело в самой гипотезе, а не в способе проверки?

Расстояние от клиента до продавца — самый популярный признак в таких задачах. Мы посмотрели на распределения: медиана и у мошенничества, и у честных покупок — 78,2 км. Признак ничего не различает, и никакой способ проверки этого не изменит. Причина в самих данных: генератор ставит продавца случайно рядом с домом.

«Мошенник сначала проверяет карту мелкой суммой» — первая мошенническая операция серии в медиане стоит 311 у.е., лишь около 10% дешевле 10 у.е. Такого поведения в данных нет.

Почему мы уверены, что проблема не в проверке: - у всех признаков одна и та же линейка, одна политика и один период; - на тех же условиях другие признаки дают плюс с интервалом выше нуля; - тест на утечку мы проверили на заведомо «подглядывающих» признаках — он их ловит; - для отвергнутых признаков мы смотрели на сами данные (распределения), а не только на итоговое число.

Ещё отвергнуто: «первая покупка у продавца» (у честных это 37% операций), «разнообразие категорий в серии» (-2,0 тыс., интервал ниже нуля), окно «операций за 24 ч» (ничего сверх плавной памяти), обучение без меток (167 тыс. против 235).

3. Почему выбрали эту модель? Что рассматривали и от чего отказались?

Рассматривали четыре варианта, каждый со своей целью: - **Логистическая регрессия (А)** — проверить, хватит ли простой модели, если признаки хорошие. **Не хватило:** на тех же признаках 224 тыс. против 245 тыс. у деревьев. Простая модель не понимает, что мошенничество в «покупках онлайн» дорогое (медиана ~1000 у.е.), а в «топливе» дешёвое (~11 у.е.): у неё «больше сумма = больше риск» одинаково для всех категорий. - **LightGBM с запретом снижать риск при росте активности (В)** — ради предсказуемости. По деньгам разница в пределах шума. - **LightGBM,**

который «учится деньгам» (С) — дорогой пропущенный фрод при обучении весит больше. Небольшой стабильный плюс (+2–3 тыс.). - **Isolation Forest без меток (С, контроль)** — 167 тыс. против 235 тыс. Отказались: необычное ≠ мошенническое, а метки у нас есть.

Финал — LightGBM, который учится деньгам. Деревья сами находят сочетания «ночь × онлайн × крупная сумма», спокойно работают с пропусками (новая карта) и быстро считаются. Параметры стандартные, без подбора — это решение мы приняли сознательно, по совету ТЗ.

4. Что изменится, если заменить вашу модель на любую другую? Что тогда на самом деле делает работу?

Мы проверили это напрямую: поменяли модели местами на всех наборах признаков (турнир). - Любое дерево на одних и тех же признаках — разница до 3,3 тыс. (шум). - Добавление признаков А+В — +13,6...14,8 тыс. на любом дереве. - Правило выбора по деньгам — +69 тыс. на одной и той же модели.

Работу делают правило выбора и признаки по истории карты. Заметно хуже станет только при переходе на линейную модель (от -17 до -62 тыс.), потому что ей не хватает сочетаний «сумма × категория × время».

5. Какой признак самый сильный и почему он важен с точки зрения заказчика — без ссылок на важность признаков из модели?

«Сколько денег списано с карты за последние сутки». Для заказчика это прямо деньги: чем больше уже ушло, тем больше потеряет банк, если вор продолжит. Мерили не «важностью в модели», а деньгами: добавление этого признака дало +10,9 тыс. у.е. с интервалом [6,8; 15,5] тыс. — точно не случайность. Аналитику он тоже понятен: «за сутки по карте уже списано 4 870 у.е.».

У А самый сильный — «клиент в последние дни тратит крупнее обычного» (+17,2 тыс. в простой модели, +10,5 тыс. в дереве).

6. Как вы отличаете сильный признак от заглядывания в будущее? Приходилось ли что-то выбрасывать по этой причине?

Каждый признак прошёл автоматический тест. Берём дату Т и считаем признаки два раза: только по данным до Т и по всему файлу. Для операций до Т значения должны совпасть. Если значение поменялось, когда мы «дописали будущее», значит признак его видел. Все 31 признак тест прошли.

Сам тест мы проверили на заведомо плохих признаках — «сколько всего операций у карты за весь период» и «пауза до следующей операции». Он их поймал, а честную «паузу с прошлой операции» пропустил.

Выбросили: вариант признаков С, где метки мошенничества берутся «в тот же день». Тест поймал его как утечку: вечерние метки того же дня уже известны утренним операциям. Поэтому у С метки только с задержкой, и в основном варианте задержка 30 дней, как в банке.

Ещё правило: если результат подозрительно хорош, сначала ищем утечку.

7. Что делает пайплайн на первой в жизни операции нового клиента?

Не падает и оценивает нормально: - **А:** профиль новой карты = профиль «среднего клиента». Неожданность категории и времени считается относительно всех клиентов; с каждой операцией профиль становится своим. - **В:** паузы нет (пусто — дерево это понимает), памяти о прошлых операциях нет (0), обычный темп карты берётся средний по всем. - **С:** «сумма дороже X% покупок в этой категории» работает сразу — для этого история клиента не нужна.

Реальный пример с холдаута: 07.06.2020, 22:10, первая операция новой карты — 1 324,80 у.е. в «покупках в магазине». Система поймала её с вероятностью 75% и написала причину «Новая карта: это её первая операция». В тестах score . ru не падает на незнакомой карте, продавце, категории, файле из одной строки и битой дате.

8. Почему такой порог? Что с деньгами, если мошенничества станет втрое больше?

Порога 0,5 у нас нет. Каждый день система отправляет операции, у которых ожидаемая польза проверки больше нуля, начиная с самых выгодных, пока не кончится лимит (0,3% операций дня $\approx$ 7). Порог появляется сам из цифр заказчика: проверка 3 у.е., ложная остановка 25, пропуск — сумма + 5. Например, покупку на 3 918 у.е. проверяем даже при вероятности 2%: проверка стоит 3, пропуск — почти 3 924.

Если мошенничества станут втрое больше (холдаут, пересчёт): - при лимите 0,3% пропущено 558 875 у.е. за два месяца — аналитиков катастрофически не хватит; - при 0,5% (~10 проверок в день) — 232 918; - при 1% (~15 в день) — 25 712; - после 15–16 проверок в день экономия почти не растёт. Так заказчик может посчитать, сколько людей нанимать.

Цена ложной остановки (10, 25 или 50 у.е.) почти не меняет результат: 323 670 / 323 389 / 322 957.

9. Почему ваша метрика подходит этой задаче? Какое решение заказчика от неё зависит?

Метрика — **экономленные деньги при лимите аналитиков**. Заказчик решает, какие операции остановить сегодня, и ему важны деньги, честные клиенты и штат. Наша метрика прямо учитывает все три: цену проверки, цену ложной остановки и лимит.

Почему не другие: - **доля правильных ответов** — 99,4% у модели «всё в порядке»; - **PR-AUC** не знает ни про суммы, ни про лимит. Мы видели это вживую: признак поднял PR-AUC с 0,48 до 0,71, а экономия упала на 43 тыс. Модель стала находить мелкое мошенничество и тратить на него проверки.

Рядом всегда показываем «потолок» (идеальную модель), правило «проверять самые дорогие» и число зря остановленных клиентов.

10. Как вы работали с дисбалансом и что это сделало с вероятностями на выходе?

- **Не дублировали редкие примеры и не выбрасывали частые** (без SMOTE и undersampling). Искусственные операции ломают признаки по истории карты (у поддельной строки нет настоящей истории) и искажают вероятности.
- **В финале — веса по деньгам:** пропущенный фрод весит «сумма + 5», честная операция — 28. Модель сильнее старается не пропустить дорогое.
- **Что это сделало с вероятностями:** из-за весов модель завышает вероятности, поэтому после неё стоит **калибровка** — подгонка на проверочном периоде, чтобы «30%» значило

«3 из 10». Проверили на холдауте: у операций с ненулевым скором предсказано в среднем 61% мошенничества, фактически 60%. Без калибровки формула пользы проверки считала бы неправду.

Кстати, данные мы не сокращали: 1,3 млн строк целиком помещаются в память, все признаки считаются меньше чем за 20 секунд.

11. Аналитику пришла ваша операция и три причины. Ему этого хватит?

Скорее да — для первого решения. Пример: > 08.06.2020, 23:49, 1 215,89 у.е. · 1) за последние сутки по карте уже списано около 4 870 у.е. · 2) сумма дороже 99% покупок в этой категории · 3) серия из 5 операций ночью

Что мы сделали, чтобы хватило: - причины обычными словами, с числами клиента («в 453 раза больше обычного, обычно ≈ 9 у.е.»); - показываем причину, только если она правда верна: «ночная» — только ночью, «новая карта» — только если у карты мало истории; - у всех 406 отправленных на холдауте по три причины.

Чего не хватает (честно): ссылки на предыдущие операции серии и вероятности в понятной форме («из 10 таких операций 7 — мошенничество»). Это первое, что мы бы добавили в карточку.

12. Мошенники подстроятся под вашу модель за месяц. Что дальше?

- **Что им придётся делать:** тратить «как хозяин» (А) и медленно (В). Медленная кража — это меньше украденных денег, то есть наша цель частично достигнута.
- **Что заметим:** падает доля подтверждённого фрода среди проверенных (сейчас 93%), меняются распределения ключевых признаков (сумма за сутки, неожиданность времени), растут потери по жалобам, которые мы не поймали.
- **Что делать:** регулярно переобучать на свежих метках; сравнивать с простым правилом «самые дорогие» на свежих данных; держать признаки из разных сценариев (А, В, С), чтобы обход одного не обходил всё.

13. Что вы сделали бы иначе, будь у вас ещё неделя?

- Переобучить финал на всех данных до июня 2020 перед эксплуатацией. Сейчас сдаём ровно ту модель, которая прошла честную проверку.
- Настоящий поток: хранить не всю историю, а короткое «состояние карты» (счётчики, память) и суточный счётчик отправленных аналитикам.
- Улучшить карточку аналитика: показывать всю серию операций.
- Проверить на данных другого источника: наши данные синтетические, и выводы вроде «расстояние бесполезно» могут не перенестись на настоящий банк.

Вопросы, которые могут задать следом

Почему финал — А и В вместе, если В один почти такой же? По деньгам лучшие варианты отличаются на сотни у.е. — это шум. Поэтому мы разобрали, кто что ловит. А лучше ловит первую операцию кражи (12 082 у.е. против 10 938 у В), когда серии ещё нет. В лучше ловит продолжение серии (240 841 против 234 186). Вместе ловят оба сценария и реже всех останавливают честных клиентов: 27 за два месяца против 35 у В и 76 у базовой модели.

Почему не взяли «запрет снижать риск» (монотонность) в финал? По деньгам в пределах шума (253 057 против 252 522), а честных остановок с ним больше (34 против 27). При равных деньгах выбрали меньше обиженных клиентов.

Как разбивали данные? Только по времени: обучение — до 20.02.2020, проверка идей — 21.02–21.04, отложенный период — 22.04–21.06. Случайное перемешивание дало бы признакам «по истории» подсмотреть соседние операции той же серии.

Почему признаки С (риск категории) не взяли? Дереву они не нужны: оно и так видит категорию и час, а доля мошенничества по ним — та же информация второй раз. Линейной модели они помогли (+9,2 тыс.). В финал вошла одна идея С — «сумма дороже X% покупок категории»: она работает с первой операции новой карты.

Что такое «потолок» и почему 98,7% — это не подозрительно? Потолок — модель, которая знает правду и берёт самые дорогие мошенничества дня. Мы близко к нему, потому что задача здесь не «найти всё», а «найти 7 самых дорогих в день», а дорогое мошенничество в этих данных заметное (ночь, онлайн, крупная сумма, серия). Утечку мы проверяли отдельно — тест на всех признаках. И на отложенном периоде результат тот же (98,7% против 98,8%), значит под проверочный период мы не подогнали.

Как score.py справляется с 550 тыс. строк? 32 секунды, 2 ГБ памяти (лимит — 10 минут и 8 ГБ). История всех прошлых операций (без меток и персональных данных) хранится в артефактах: у знакомых карт признаки продолжают с того же места. Вероятности score.py на холдауте совпадают с оценкой до $4 \cdot 10^{-7}$ — признаки при обучении и при скоринге считает один и тот же код.

Что было самым неожиданным? Что главный эффект дали не признаки и не модель, а правило выбора операций по деньгам: +69 тыс. на той же модели.

Каждое решение в пяти фразах (чтобы рассказать чужое)

А — «Так хозяин карты не платит». Сравниваем операцию с прошлым этой карты: редкая категория, непривычное время, сумма больше обычной в этой категории. Неожиданность в битах, у новой карты профиль «среднего клиента» — пропусков нет. Простая модель (LogReg), чтобы проверить, хватит ли её, — не хватило (224 против 245 тыс. на деревьях). Лучшие признаки: «крупная сумма в непривычное время» и «последние дни тратит крупнее». Лучше всех ловит первую операцию кражи.

В — «Карту выкачивают». Мошенничество идёт сериями: ~10 операций за двое суток, пауза ~1 час. Плавная память вместо окна «24 часа»; активность сравниваем с нормой этого клиента; поток режим на «сессии атаки». Сильнейший признак — сколько списано за сутки (+10,9 тыс.). Модели запрещено снижать риск при росте активности — бесплатно по деньгам. 98,4% потолка, лучше всех ловит продолжение серии.

С — «Что выгоднее проверить сегодня». Выбор операций по ожидаемой пользе проверки — +69 тыс., самый большой эффект проекта. Модель учится деньгам: дорогой фрод весит больше. Риск категорий — только по меткам старше 30 дней, как в банке; реализм ничего не стоил, а «метки того же дня» тест поймал как утечку. Признаки среды деревьям не нужны, линейной модели дали +9,2 тыс. Без меток (Isolation Forest) — сильно хуже: необычное ≠ мошенническое.